Taller 1 — KNN y Métricas de Clasificación

Aprendizaje Automático de Máquina I

Semestre 2026-2

Estudiante: Over Haider Castrillón Valencia

Programa: Maestría en Matemáticas y Ciencias de la Computación

Profesor: Daniel Felipe Rambaut Lemus

Modalidad: Individual

Fecha: 6 de septiembre de 2026



Índice

1. Componente teórico-matemático **2**
1.1. Ejercicio 1 — Fundamento probabilístico de KNN 2
1.2. Ejercicio 2 — Distancia euclidiana vs. Manhattan 3
1.3. Ejercicio 3 — Efecto de la escala sobre la distancia 4
1.4. Ejercicio 4 — Matriz de confusión y métricas básicas 5
1.5. Ejercicio 5 — Comparación de dos modelos y costo de clasificación 6

2. Componente práctico-computacional **8**
2.1. Ejercicio 6 — Exploración inicial y preparación de datos 8
2.2. Ejercicio 7 — KNN con $k = 5$: sin escalar vs. estandarizado 9
2.3. Ejercicio 8 — Efecto del número de vecinos k 10
2.4. Ejercicio 9 — Distancia Euclidiana vs. Manhattan 11
2.5. Ejercicio 10 — Análisis final y costo de negocio 11

1. Componente teórico-matemático

1.1. Ejercicio 1 — Fundamento probabilístico de KNN

Sea un conjunto de entrenamiento $D = \{(x_i, y_i)\}_{i=1}^{n}$, con $x_i \in \mathbb{R}^d$, $y_i \in \{0, 1\}$. Para una nueva observación x, sea $N_k(x)$ el conjunto de sus k vecinos más cercanos, y defínase

$$\hat{p}_k(x) = \frac{1}{k} \sum_{x_i \in N_k(x)} y_i.$$

a. $\hat{p}_k(x)$ **es una proporción.** Dado que $y_i \in \{0, 1\}$, cada etiqueta funciona como una variable indicadora de forma que $y_i = 1$ aporta exactamente una unidad a la suma cuando el vecino pertenece a la clase positiva, mientras que $y_i = 0$ no aporta nada, por lo tanto,

$$\sum_{x_i \in N_k(x)} y_i = \#\{x_i \in N_k(x) : y_i = 1\} = m,$$

es decir, la sumatoria cuenta literalmente cuántos de los k vecinos son positivos sin que los negativos alteren el resultado, y al dividir entre k se obtiene $\hat{p}_k(x) = m/k$, que corresponde exactamente a la definición frecuentista de una proporción (casos favorables sobre casos totales), quedando así demostrado que $\hat{p}_k(x)$ es la proporción de vecinos de clase positiva.

b. **El umbral $\frac{1}{2}$ como regla de mayoría.** KNN asigna a x la clase mayoritaria entre sus k vecinos, de forma que, si m es el número de vecinos positivos, entonces $k - m$ es el de negativos, y la clase 1 es mayoritaria cuando $m > k - m$, lo cual equivale a $2m > k$, es decir, a $m/k > \frac{1}{2}$ (y como $\hat{p}_k(x) = m/k$, esta condición es exactamente $\hat{p}_k(x) > \frac{1}{2}$), con lo cual el umbral no se impone arbitrariamente sino que es la traducción algebraica explícita a la regla "la clase con más votos gana".

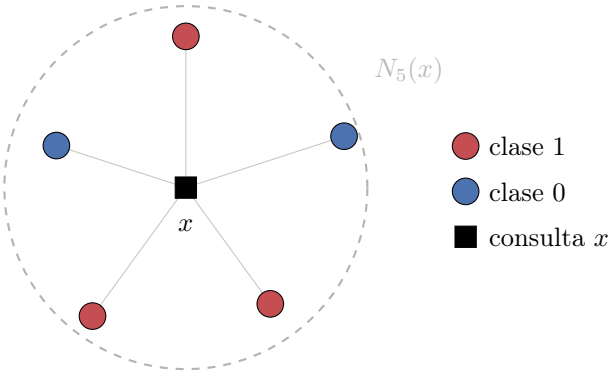
c. **Caso $k = 5$, etiquetas $\{1, 0, 1, 1, 0\}$.**

$$m = 1 + 0 + 1 + 1 + 0 = 3, \qquad \hat{p}_k(x) = \frac{3}{5} = 0.6 > 0.5 \implies \text{KNN predice la } \textbf{clase 1}.$$

d. **Caso $k = 7$, etiquetas $\{0, 0, 1, 0, 1, 1, 0\}$.**

$$m = 0+0+1+0+1+1+0 = 3, \qquad \hat{p}_k(x) = \frac{3}{7} \approx 0.4286 < 0.5 \implies \text{KNN predice la } \textbf{clase 0}.$$

e. **Por qué k impar evita empates.** Un empate ocurre cuando $m = k - m$, es decir, cuando $k = 2m$, esta igualdad exige que k sea par (porque $2m$ es siempre un número par para cualquier entero m), de modo que si k es impar no existe ningún entero m que satisfaga $k = 2m$, y el empate resulta matemáticamente imposible, que es justo lo que se observó en los incisos c y d, donde al ser k impar en ambos casos, $\hat{p}_k(x)$ nunca cae exactamente en 0.5 y siempre hay una clase estrictamente mayoritaria.



3 votos de clase 1 contra **2 votos de clase 0**
$\Rightarrow \ \hat{p}_5(x) = \frac{3}{5} = 0.6 > \frac{1}{2} \Rightarrow$ predicción: **clase 1**

Figura 1: Votación de KNN para el ejemplo del inciso c ($k = 5$, etiquetas $\{1, 0, 1, 1, 0\}$): cada punto de color es uno de los 5 vecinos más cercanos a x, la clase mayoritaria entre ellos es quien determina la predicción.

1.2. Ejercicio 2 — Distancia euclidiana vs. Manhattan

Sean $\mathcal{A} = (a_1, a_2)$ y $\mathcal{B} = (b_1, b_2)$, con

$$d_E(\mathcal{A}, \mathcal{B}) = \sqrt{(a_1 - b_1)^2 + (a_2 - b_2)^2}, \qquad d_M(\mathcal{A}, \mathcal{B}) = |a_1 - b_1| + |a_2 - b_2|.$$

Se consideran los puntos $A = (2, 3)$, $B = (7, 7)$, $C = (5, 2)$.

a.
$$d_E(A, B) = \sqrt{(2-7)^2 + (3-7)^2} = \sqrt{25 + 16} = \sqrt{41} \approx 6.4031$$

b.
$$d_M(A, B) = |2 - 7| + |3 - 7| = 5 + 4 = 9$$

c.
$$d_E(A, C) = \sqrt{(2-5)^2 + (3-2)^2} = \sqrt{10} \approx 3.1623, \qquad d_M(A, C) = |2 - 5| + |3 - 2| = 4$$

d. **Vecino más cercano de A.** Al comparar $d_E(A, B) \approx 6.40$ con $d_E(A, C) \approx 3.16$, y $d_M(A, B) = 9$ con $d_M(A, C) = 4$, resulta claro que en ambos casos **C** es el vecino más cercano, de forma que aquí las dos métricas coinciden en su conclusión, aunque esto no está garantizado en general, pues nada impide construir puntos donde Euclidiana y Manhattan discrepen sobre cuál es el vecino más cercano.

e. **Demostración de $d_E(A, B) \leq d_M(A, B)$.** Partiendo de la expresión sugerida y expandiendo el cuadrado del lado izquierdo

$$(|a_1 - b_1| + |a_2 - b_2|)^2 = (a_1 - b_1)^2 + 2|a_1 - b_1||a_2 - b_2| + (a_2 - b_2)^2,$$

como el término cruzado $2|a_1 - b_1||a_2 - b_2|$ es siempre no-negativo (al producto de valores absolutos), se cumple que

$$(|a_1 - b_1| + |a_2 - b_2|)^2 \ \geq \ (a_1 - b_1)^2 + (a_2 - b_2)^2,$$

es decir que $d_M(A, B)^2 \geq d_E(A, B)^2$ y, dado que ambas distancias son cantidades no negativas al tomar raíz cuadrada se preserva la desigualdad:

$$d_M(A, B) \geq d_E(A, B) \quad \Longleftrightarrow \quad d_E(A, B) \leq d_M(A, B).$$

Solo se alcanza igualdad cuando $|a_1 - b_1||a_2 - b_2| = 0$, es decir, cuando los puntos difieren en una única coordenada (geométricamente, cuando el desplazamiento es puramente horizontal o vertical).

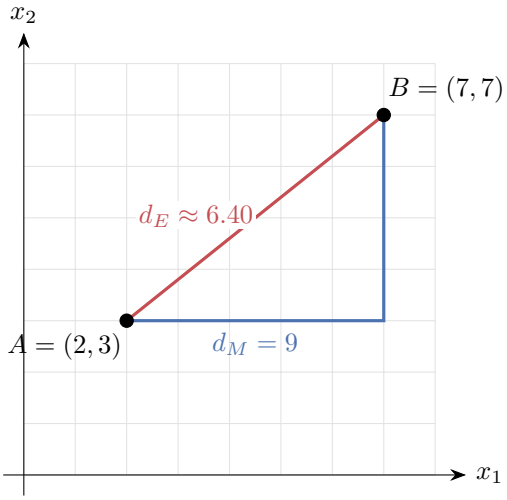


Figura 2: Trayecto directo (Euclidiana, rojo) frente al trayecto en escalera (Manhattan, azul) entre A y B: La escalera nunca puede ser más corta que la línea recta, lo que ilustra geométricamente por qué $d_E \leq d_M$.

1.3. Ejercicio 3 — Efecto de la escala sobre la distancia

Se consideran los puntos $A = (20, 1000)$, $B = (25, 1200)$, $C = (40, 1010)$.

a. **Distancias en escala original.**

$$d(A, B) = \sqrt{(20 - 25)^2 + (1000 - 1200)^2} = \sqrt{25 + 40000} = \sqrt{40025} \approx 200.06$$

$$d(A, C) = \sqrt{(20 - 40)^2 + (1000 - 1010)^2} = \sqrt{400 + 100} = \sqrt{500} \approx 22.36$$

b. **Vecino más cercano.** Como $d(A, C) \approx 22.36$ es mucho menor que $d(A, B) \approx 200.06$, el punto **C** es el vecino más cercano a A.

c. **Distancias tras dividir la segunda variable entre 100.** Con $A' = (20, 10)$, $B' = (25, 12)$, $C' = (40, 10.1)$:

$$d(A', B') = \sqrt{5^2 + 2^2} = \sqrt{29} \approx 5.385$$

$$d(A', C') = \sqrt{20^2 + 0.1^2} = \sqrt{400.01} \approx 20.0002$$

d. **¿Cambió el vecino más cercano?** Sí, ahora $d(A', B') \approx 5.39 < d(A', C') \approx 20.00$ así que el vecino más cercano pasó a ser **B**, el punto opuesto al de antes de reescalar pero esto tiene una explicación directa: En la escala original la segunda variable (diferencias en centenas) dominaba por completo el cálculo, mientras que al dividirla entre 100 su diferencia se vuelve comparable a la de la primera variable y esta última antes irrelevante, ahora pasa a determinar la distancia.

e. **Por qué una escala mayor domina la distancia.** En la expresión general

$$d(x, z) = \sqrt{\sum_{j=1}^{d} (x_j - z_j)^2},$$

cada variable contribuye a través del cuadrado de su diferencia, de modo que si la variable j tiene un rango considerablemente mayor al de las demás (como la segunda coordenada (ordenada) de este ejercicio en orden de miles y no decenas), $(x_j - z_j)^2$ será en términos absolutos, mucho mayor que los demás términos, de forma que tanto la suma como, en consecuencia, la distancia total terminan determinadas casi exclusivamente por esa variable sin importar si conceptualmente es la más relevante para el problema, este es precisamente el motivo por el cual antes de aplicar un algoritmo basado en distancias como KNN, se recomienda estandarizar o normalizar las variables.

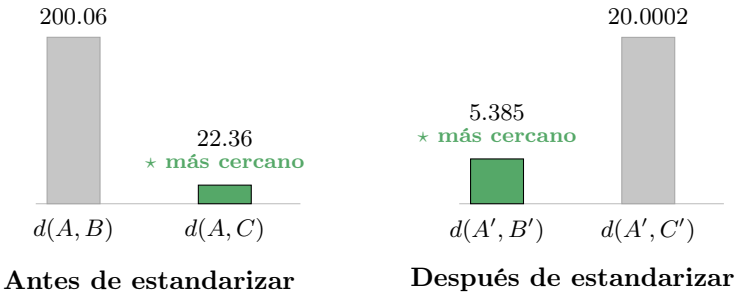


Figura 3: Cambio del vecino más cercano de A tras dividir la segunda variable entre 100 (cada panel usa su propia escala vertical, ya que las magnitudes antes y después no son comparables): pasa de ser C a ser B.

1.4. Ejercicio 4 — Matriz de confusión y métricas básicas

		Predicho	
		$\hat{Y} = 0$	$\hat{Y} = 1$
Real	$Y = 0$	850	100
	$Y = 1$	20	30

Cuadro 1: Matriz de confusión del Ejercicio 4.

a. **Identificación de TP, TN, FP, FN.** Leyendo las filas como clase real y las columnas como clase predicha, se identifica que $TN = 850$ (real 0 | predijo 0), $FP = 100$ (real 0 | predijo 1), $FN = 20$ (real 1 | predijo 0) y $TP = 30$ (real 1 | predijo 1).

b. **Accuracy.**
$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{30 + 850}{1000} = 0.88$$

c. **Precision.**
$$\text{Precision} = \frac{TP}{TP + FP} = \frac{30}{130} = \frac{3}{13} \approx 0.2308$$

d. **Recall.**
$$\text{Recall} = \frac{TP}{TP + FN} = \frac{30}{50} = 0.6$$

e. **F1.**
$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = 2 \cdot \frac{(3/13)(3/5)}{3/13 + 3/5} = 2 \cdot \frac{9/65}{54/65} = \frac{18}{54} = \frac{1}{3} = 0.\overline{3}$$

f. **Demostración algebraica de $F1 = \dfrac{2TP}{2TP + FP + FN}$.**

Se parte de las definiciones $P = \dfrac{TP}{TP + FP}$ y $R = \dfrac{TP}{TP + FN}$.

Primero se calcula el producto $P \cdot R$:

$$P \cdot R = \frac{TP^2}{(TP + FP)(TP + FN)}.$$

Luego se calcula la suma $P + R$, llevándose a un denominador común:

$$P + R = \frac{TP(TP + FN) + TP(TP + FP)}{(TP + FP)(TP + FN)} = \frac{TP\,(2TP + FP + FN)}{(TP + FP)(TP + FN)}.$$

Sustituyendo ambas expresiones en $F1 = 2 \cdot \dfrac{P \cdot R}{P + R}$, el denominador común $(TP+FP)(TP+FN)$ se cancela:

$$F1 = 2 \cdot \frac{TP^2}{TP\,(2TP + FP + FN)} = \frac{2TP}{2TP + FP + FN}.$$

Verificación numérica:

$$\frac{2(30)}{2(30) + 100 + 20} = \frac{60}{180} = \frac{1}{3},$$

idéntico al resultado del inciso e.

1.5. Ejercicio 5 — Comparación de dos modelos y costo de clasificación

		Predicho	
		$\hat{Y} = 1$	
Real	$Y = 0$	900	50
	$Y = 1$	30	20

Modelo A

		Predicho	
		$\hat{Y} = 0$	$\hat{Y} = 1$
Real	$Y = 0$	850	100
	$Y = 1$	10	40

Modelo B

Cuadro 2: Matrices de confusión de los dos modelos comparados.

a. **Métricas de cada modelo.**

Modelo A $(TN = 900, FP = 50, FN = 30, TP = 20)$:

$$\text{Acc}_A = 0.92, \quad \text{Prec}_A = \tfrac{20}{70} = 0.\overline{285714}, \quad \text{Rec}_A = 0.4, \quad F1_A = \tfrac{1}{3} = 0.\overline{3}.$$

Modelo B $(TN = 850, FP = 100, FN = 10, TP = 40)$:

$$\text{Acc}_B = 0.89, \quad \text{Prec}_B = \tfrac{40}{140} = 0.\overline{285714}, \quad \text{Rec}_B = 0.8, \quad F1_B = \tfrac{8}{19} \approx 0.4211.$$

b. **Costo $L = FP + 5FN$.**

$$L_A = 50 + 5(30) = 200, \qquad L_B = 100 + 5(10) = 150.$$

c. **Mayor Accuracy:** el Modelo A $(0.92 > 0.89)$.

d. **Mayor Recall:** el Modelo B $(0.8 > 0.4)$, por amplio margen.

e. **Menor costo:** el Modelo B ($150 < 200$).

f. **El modelo de mayor Accuracy no minimiza el costo.** El Modelo A tiene mayor Accuracy pero un mayor coste asociado que el Modelo B, esto sucede porque lo que hace el Accuracy es ponderar todos los errores por igual, mientras que L pondera cada falso negativo cinco veces más que cada falso positivo: el Modelo A minimiza el número total de errores (80 en vez de 110), pero comete más falsos negativos (30 y no 10), que son los más costosos, mientras que el Modelo B sí compensa con más falsos positivos (100 en vez de 50), los que son baratos. Cuando los dos tipos de error tienen consecuencias distintas, elegir un modelo únicamente por el Accuracy puede ser una decisión subóptima enmarcada en el costo real del negocio.



2. Componente práctico-computacional

Los ejercicios 6 a 10 se desarrollaron en Python sobre el conjunto de datos *Give Me Some Credit* (150.000 observaciones); el notebook reproducible correspondiente se entrega por separado (en formato `.ipynb`) produciendo todos los valores y figuras citados en esta sección.

2.1. Ejercicio 6 — Exploración inicial y preparación de datos

a–c. Carga del dataset y diagnóstico general

El conjunto de datos *Give Me Some Credit* contiene 150.000 observaciones y 11 variables (10 predictoras más la variable objetivo `SeriousDlqin2yrs`) de las cuales 6 son de tipo entero [`int64`], 4 de tipo decimal [`float64`] y solo dos presentan valores faltantes: `MonthlyIncome` (29.731 faltantes, 19.82 %) y `NumberOfDependents` (3.924 faltantes, 2.62 %), mientras que el resto de variables no tiene ningún faltante.

d. Balance de clases

Clase	n	%
0 (no incumple)	139.974	93.32
1 (incumple)	10.026	6.68

Cuadro 3: Distribución de la variable objetivo `SeriousDlqin2yrs`.

Casi 14 casos negativos por cada positivo: Un modelo trivial que siempre prediga la clase 0 ya alcanzaría cerca de 93 % de Accuracy sin ser útil en la práctica, de modo que la Precision, Recall y F1 sobre la clase 1 serán las métricas que realmente den informen del desempeño.

e. Gráfica

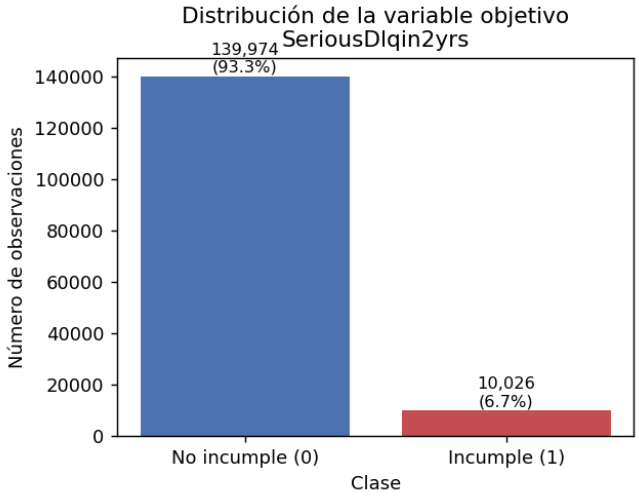


Figura 4: Distribución de la variable objetivo.

f. Tratamiento de valores faltantes

Se imputó con la **mediana** de cada variable en lugar de la media ya que ambas variables con faltantes tienen colas largas hacia la derecha (unos pocos ingresos o números de dependientes

extremadamente altos que arrastrarían la media), la mediana resulta mucho más robusta frente a esos valores atípicos, usando como referencia `MonthlyIncome` = 5.400 y `NumberOfDependents` = 0.

g. Partición 80/20 estratificada

Conjunto	Clase 0 (n)	Clase 0 (%)	Clase 1 (n)	Clase 1 (%)
Entrenamiento (120.000)	111.979	93.32	8.021	6.68
Prueba (30.000)	27.995	93.32	2.005	6.68

Cuadro 4: Distribución de clases en entrenamiento y prueba.

Se usó `train_test_split(X, y, test_size=0.2, stratify=y, random_state=42)` (la estratificación busca mantener la proporción de clases prácticamente idéntica entre *train* y *test*), evitando que el azar de la partición produzca un subconjunto con una tasa de incumplimiento notablemente distinta a la del conjunto completo (lo cual sesgaría la evaluación).

2.2. Ejercicio 7 — KNN con $k = 5$: sin escalar vs. estandarizado

Modelo	Accuracy	Precision	Recall	F1
Sin escalamiento	0.9326	0.4224	0.0244	0.0462
Estandarizado	0.9329	0.4936	0.1357	0.2128

Cuadro 5: Comparación $k = 5$, sin escalar vs. estandarizado.

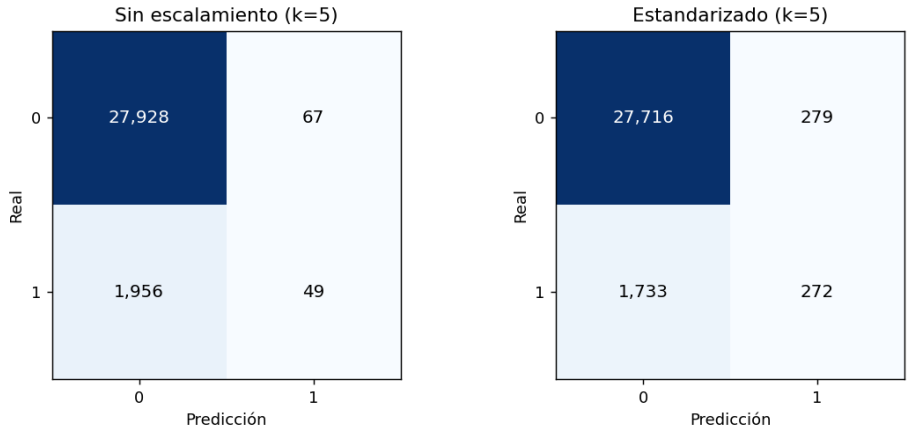


Figura 5: Matrices de confusión, $k = 5$.

a. **¿Cambió el desempeño tras estandarizar?** Sí, de forma sustancial en su capacidad de detectar la clase positiva: El Accuracy apenas se mueve (0.9326 → 0.9329), pero el Recall se multiplica por más de 5 veces (0.0244 → 0.1357) y el F1 por más de 4 veces (0.0462 → 0.2128).

b. **Métrica con el cambio más importante.** El **Recall**, y esto es consistente con lo demostrado en el Ejercicio 3e, pues sin estandarizar las variables como `MonthlyIncome` o `DebtRatio` (con rangos de miles) dominan el cálculo de distancias por encima de `age` o

`NumberOfDependents` (con rangos de decenas o unidades) y el modelo termina casi ignorando estas últimas, mientras que al estandarizar todas aportan en una escala comparable y el modelo pasa de detectar apenas 49 de los 2.005 incumplimientos reales a detectar 272 de los mismos 2.005.

c. **Modelo elegido.** Se recomienda el modelo **estandarizado**, aunque el Accuracy es prácticamente igual el Recall y el F1 son considerablemente superiores, para en un problema de riesgo crediticio, donde no detectar un incumplimiento suele costar más que lanzar una alerta equivocada (véase el Ejercicio 10) esa mejora resulta preferible en casi cualquier escenario de negocio razonable.

2.3. Ejercicio 8 — Efecto del número de vecinos k

k	Accuracy	Precision	Recall	F1
1	0.9044	0.2496	0.2144	**0.2307**
3	0.9276	0.3978	0.1621	0.2303
5	0.9329	0.4936	0.1357	0.2128
7	0.9345	0.5412	0.1277	0.2066
9	**0.9350**	0.5652	0.1167	0.1935
11	0.9346	0.5583	0.1027	0.1735
15	0.9343	0.5549	0.0883	0.1523
21	0.9348	0.5863	0.0813	0.1428

Cuadro 6: Métricas por valor de k (datos estandarizados).

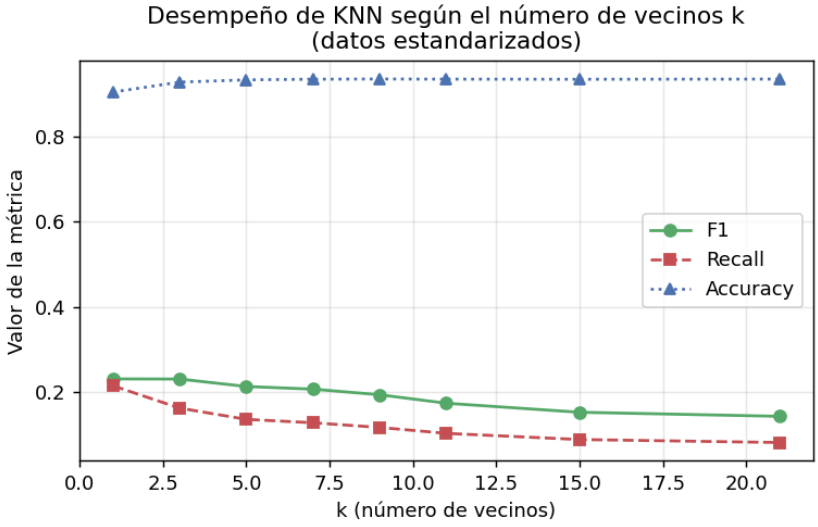


Figura 6: Desempeño de KNN según el número de vecinos k.

a. **Mejor F1:** $k = 1$ ($F1 = 0.2307$).

b. **Mejor Recall:** $k = 1$ (Recall $= 0.2144$).

c. **Mejor Accuracy:** $k = 9$ (Accuracy $= 0.9350$).

d. **¿Coinciden los tres criterios en el mismo modelo?** No, pues F1 y Recall se maximizan en $k = 1$ mientras que Accuracy se maximiza en $k = 9$, y esto tiene una razón de fondo: Al aumentar k el modelo promedia sobre vecindarios cada vez más grandes que, dado el fuerte desbalance de clases (93 %/7 %), terminan dominados por vecinos de la clase mayoritaria, empujando las predicciones hacia la clase 0 y sacrificando Recall a cambio de un Accuracy apenas mayor, mientras que $k = 1$, al fijarse solo en el vecino más próximo, es mucho más sensible a los pocos vecinos positivos cercanos, favoreciendo el Recall aunque a costa de una mayor varianza (más falsos positivos, como en el Ejercicio 10).

2.4. Ejercicio 9 — Distancia Euclidiana vs. Manhattan

Se comparan los tres mejores valores de k según F1 obtenidos en el Ejercicio 8: $k = 1, 3, 5$.

k	Distancia	Accuracy	Precision	Recall	F1
1	Euclidiana	0.9044	0.2496	0.2144	**0.2307**
1	Manhattan	0.9054	0.2518	0.2105	0.2293
3	Euclidiana	0.9276	0.3978	0.1621	0.2303
3	Manhattan	0.9283	0.4000	0.1466	0.2146
5	Euclidiana	0.9329	0.4936	0.1357	0.2128
5	Manhattan	0.9329	0.4921	0.1237	0.1977

Cuadro 7: Euclidiana vs. Manhattan para $k \in \{1, 3, 5\}$.

a. **¿La métrica modifica el desempeño?** Sí, pero de forma mucho más discreta que la estandarización o que k, y sin un patrón del todo consistente, pues para $k = 1$ y $k = 3$ Manhattan da Accuracy y Precision levemente superiores pero Recall y F1 levemente inferiores a Euclidiana, mientras que para $k = 5$ ocurre lo contrario y la Euclidiana iguala o supera a Manhattan en las cuatro métricas (obsérvese la Precision de 0.4936 para Euclidiana y no 0.4921 como en la Manhattan), aunque en ningún caso la diferencia entre métricas supera 1.5 puntos porcentuales, muy por debajo del efecto de estandarizar o de cambiar k.

b. **Mayor F1:** $k = 1$, Euclidiana ($F1 = 0.2307$).

c. **Mayor Recall:** $k = 1$, Euclidiana (Recall $= 0.2144$).

d. **¿Coinciden F1 y Recall en la misma configuración?** Sí, ambas apuntan a $k = 1$ con distancia euclidiana, aunque vale la pena matizar dicha coincidencia ya que los tres valores de k comparados aquí ya fueron preseleccionados por ranking de F1 en el Ejercicio 8, y en este dataset el Recall resulta monótonamente decreciente en k (↑ k, ↓ Recall), así que el ranking de F1 y el de Recall casi tenían que coincidir dentro de ese subconjunto de tres, por lo que no es del todo una confirmación independiente. Dicho esto, el mecanismo de fondo sí es real, pues a diferencia del trade-off marcado entre $k = [1, 9]$ del Ejercicio 8, aquí cambiar la métrica de distancia no altera lo suficiente cuál vecino es "más cercano" como para invertir el orden de los modelos, ya que con los datos ya estandarizados la diferencia entre penalizar cuadráticamente (Euclidiana) o linealmente (Manhattan) las diferencias por variable resulta menor que la que introduce cambiar k.

2.5. Ejercicio 10 — Análisis final y costo de negocio

Se comparan tres modelos representativos: El de mejor F1/Recall ($k = 1$, Euclidiana, estandarizado), el de mejor Accuracy ($k = 9$, Euclidiana, estandarizado), y el modelo base sin estandarizar ($k = 5$, Ejercicio 7).



Modelo	k	FP	FN	Recall	F1	Costo L
Modelo 1 (mejor F1/Recall)	1	1.293	1.575	0.2144	0.2307	**9.168**
Modelo 2 (mejor Accuracy)	9	180	1.771	0.1167	0.1935	**9.035**
Modelo 3 (base, sin estandarizar)	5	67	1.956	0.0244	0.0462	**9.847**

Cuadro 8: Comparación final de modelos, con $L = FP + 5FN$.

a. **¿El modelo de mayor Accuracy es también el de menor costo?** En este caso concreto, **sí**, ya que el Modelo 2 tiene simultáneamente el mayor Accuracy (0.9350) y el menor costo (9.035) de los tres, aunque vale la pena anotarlo con honestidad: esto **no contradice** lo demostrado teóricamente en el Ejercicio 5f, donde se construyó un ejemplo específico en el que Accuracy y costo mínimo sí divergían, sino que simplemente muestra que la relación entre ambas métricas depende de la forma concreta de los errores de cada modelo y no es ninguna ley universal, pues aquí el modelo con más vecinos ($k = 9$) resulta lo bastante conservador (con muy pocos FP) como para también minimizar el costo, algo que podría no sostenerse con otra función de costo o con otro dataset.

b. **¿Menor número de falsos negativos?** El **Modelo 1** ($k = 1$), con 1.575 FN en vez de los 1.771 del Modelo 2 o los 1.956 del Modelo 3.

c. **¿Qué modelo recomendaría para identificar clientes de alto riesgo?** El **Modelo 1**, a pesar de no tener ni el mayor Accuracy ni el menor costo L, y esto porque si el objetivo explícito es maximizar la detección de incumplimientos reales (priorizando el Recall), el Modelo 1 detecta 430 de los 2.005 incumplimientos del conjunto de prueba (21.44 %), casi el doble que el Modelo 2 (234 de 2.005, 11.67 %), y aunque el costo L tal como está definido pondera los falsos positivos con peso 1, esto puede subestimar el valor real de detectar más incumplimientos si, en la práctica, el costo de no detectar a un mal pagador termina siendo incluso mayor a 5 veces el de una alerta equivocada.

d. **Justificación final.** La comparación deja en evidencia una tensión real entre tres criterios de selección (Accuracy, un costo explícito ponderado, y Recall puro) que no siempre apuntan al mismo modelo, siendo el Modelo 2 la opción más conservadora y "eficiente en costo" bajo la L definida aquí, mientras que el Modelo 1 es la más agresiva en detección de riesgo, y por eso la elección final no es un ejercicio puramente estadístico sino una decisión de negocio que depende de cuánto le cuesta realmente a la institución cada tipo de error, ya que si ese costo relativo real fuera mayor a 5:1, el balance se inclinaría todavía más hacia el Modelo 1.

